

Louay Guetat

INGÉNIEUR IA

Tunis, Tunisie · Ouvert à la mobilité internationale

+216 55 160 398 | louay.guetat1@gmail.com | louayguetat.github.io

LinkedIn : linkedin.com/in/guetat-louay | GitHub : github.com/Louay-Guetat

Ingénieur IA spécialisé dans les systèmes multi-agents, l'intégration de LLM et les pipelines RAG, appuyé par une solide base full-stack. Je construis des plateformes IA de production de bout en bout — de la récupération et l'orchestration d'agents aux APIs et interfaces qui les livrent — en mettant l'accent sur l'évaluation, les garde-fous et des résultats fiables et sourcés. Je développe actuellement des agents de recherche financière et une plateforme de due diligence IA pour les marchés privés.

EXPÉRIENCE PROFESSIONNELLE

Ingénieur IA — Alpha Momentum

Télétravail · Startup américaine | Février 2025 – Présent

Direction du développement IA/ML d'une plateforme de recherche financière fondée sur des systèmes multi-agents, des pipelines RAG et un traitement intelligent des données, tout en assurant l'infrastructure full-stack associée (web React, mobile React Native, API serverless Node.js). Depuis août 2026, je pilote également Capital Thread, une plateforme de due diligence IA pour les marchés privés (détaillée dans Projets sélectionnés), via Alpha Momentum.

- Architecture d'un système multi-agents avec LangChain et LangGraph — agents spécialisés pour la recherche actions, la valorisation, l'optimisation de portefeuille, le risque, l'analyse technique et le sentiment de marché — intégrant plusieurs fournisseurs LLM (OpenAI, Anthropic, Google Gemini, xAI, Groq, SambaNova, Ollama) avec sélection dynamique et mécanismes de repli
- Développement de Dexter, un agent de recherche financière doté d'outils personnalisés pour la recherche financière, l'analyse de documents SEC, la recherche web (Tavily/Exa) et l'automatisation de navigateur (Playwright), avec un système de compétences basé sur markdown pour des analyses spécialisées (modèles DCF, options) et métadonnées frontmatter
- Construction d'un framework d'évaluation avec évaluation par critères, validation de la précision numérique, analyse de la sélection d'outils et intervalles de confiance, utilisant LangSmith pour le traçage et le suivi des performances à travers les itérations d'agents
- Implémentation d'un pipeline RAG avec chunking intelligent, embeddings OpenAI, stockage graphe Neo4j pour les relations sémantiques et une récupération optimisée sur les documents financiers pour des réponses contextuelles
- Développement de services FastAPI pour le traitement de documents SEC (edgartools + parseurs personnalisés), extrayant des données structurées des filings 10-K, 10-Q et 8-K, avec orchestration AWS Batch pour plus de 37 000 documents et mises à jour incrémentales
- Construction de pipelines d'ingestion de données Python (BeautifulSoup, Selenium, aiohttp) pour FMP, la Réserve fédérale, la BCE, les actualités, les transcriptions de résultats et les signaux de marché, avec logging structuré et gestion d'erreurs

- Ingénierie de la couche de livraison full-stack : application web React 18 + TypeScript avec streaming IA en temps réel (SSE), API serverless Node.js avec intégration LangChain, applications React Native et CI/CD GitHub Actions vers Docker/AWS

Stack Technique : Python (FastAPI, LangChain, LangGraph, LangSmith, Pandas, NumPy), OpenAI, Anthropic, Google Gemini, xAI, Groq, Neo4j, MongoDB, Redis, Docker, AWS (Lambda, ECS, ECR, Batch), edgartools, BeautifulSoup, Selenium, Playwright, TypeScript, React, Node.js

Stagiaire Data Science — Sagemcom

Tunis | Février 2024 – Août 2024

- Développement de systèmes multi-agents avec intégration LLM et récupération basée sur embeddings
- Construction d'un pipeline de données de bout en bout — scraping et constitution de jeux de données (Selenium, BeautifulSoup), récupération avec modèles HuggingFace et LangChain, workflows automatisés avec LangGraph
- Développement d'une interface web ReactJS + Flask pour les interactions avec les modèles via une API REST

Technologies : Python, Flask, LangChain, LangGraph, HuggingFace, ReactJS, SQLite, REST API

Développeur Full Stack — WeTekup

Tunis | Mars 2025 – Septembre 2025

- Développement de sites web responsives en React (SCSS) avec des APIs REST Node.js/Express sur PostgreSQL
- Déploiement en production sur Hostinger avec un proxy inverse Nginx, SSL/TLS et optimisation des performances

Technologies : React, Node.js, Express.js, SCSS, PostgreSQL, Nginx

Stagiaire Full Stack — WeTekup (Khedma.site)

Tunis | Juillet 2023 – Septembre 2023

- Développement d'une plateforme de recrutement avec un front-end ReactJS et des APIs REST Django sur PostgreSQL

Technologies : ReactJS, Django, Python, PostgreSQL

PROJETS SÉLECTIONNÉS

Capital Thread — Plateforme de due diligence IA pour marchés privés · Mission client via Alpha Momentum · Août 2026 – Présent

Pipeline de diligence en un clic pour la dette privée, le private equity et le venture : sourcing des deals depuis SEC EDGAR et Form D, parsing de l'Inline XBRL, et génération de modèles financiers, valorisations DCF et mémos d'investissement où chaque chiffre renvoie à sa source. Architecture où les LLM (OpenAI, Anthropic) gèrent le jugement et la narration tandis que du code Python déterministe gère tous les calculs — ancrant les résultats et éliminant les chiffres hallucinés. 437 tests unitaires sur les moteurs financiers.

Technologies : OpenAI API, Anthropic API, FastAPI, PostgreSQL, SQLAlchemy, SEC EDGAR, ArXiv XBRL, React 19, TypeScript

Alpha Momentum — Recherche financière multi-agents · *alphamomentum.ai* · *En ligne*

Cinq workflows de recherche LangGraph et un pipeline RAG (embeddings OpenAI + Neo4j) sur un corpus SEC de plus de 37 000 documents, livrés sur le web et le mobile.

Technologies : LangChain, LangGraph, OpenAI, Anthropic, Neo4j, FastAPI, AWS Batch

Intellectia — Apprentissage des maths par la vision · *Projet en équipe*

Plateforme d'apprentissage des mathématiques pour enfants qui transforme les problèmes textuels en représentations visuelles à l'aide de modèles de vision, avec quiz interactifs et tableaux de bord de performance.

Technologies : TensorFlow, HuggingFace, React, Django, MongoDB, NumPy, Pandas

PMBOK Risk Recommender — NLP / GNN · *Projet en équipe*

Recommandeur de risques projet de type chatbot entraîné sur les données du PMBOK 11e édition, utilisant un Graph Attention Network avec un embedder BERT pour des recommandations textuelles.

Technologies : PyTorch, TensorFlow, BERT, GNN, NLP, Django, NumPy

Yoga Pose Classifier — Vision par ordinateur · *Réalisé en solo*

Classification de postures de yoga par CNN ; un CNN sur mesure a atteint 86 % de précision et ResNet 97 % sur plusieurs catégories de postures.

Technologies : Python, CNN, ResNet, Django, NumPy, Pandas

COMPÉTENCES TECHNIQUES

IA / ML & LLM : LangChain, LangGraph, LangSmith, OpenAI API, Anthropic API, Google Gemini, RAG, HuggingFace, systèmes multi-agents, évaluation de prompts/agents

Deep Learning : TensorFlow, PyTorch, Keras, scikit-learn, CNN, ResNet, BERT, GNN, NLP, Vision par ordinateur

Données : Pandas, NumPy, BeautifulSoup, Selenium, Playwright, aiohttp, SEC EDGAR, Arelle XBRL

Backend : Python (FastAPI, Flask, Django), Node.js (Express, Serverless)

Bases de données : PostgreSQL, MongoDB, Neo4j, MySQL, Redis, DynamoDB

Cloud & DevOps : AWS (Lambda, ECS, ECR, Batch, S3, CloudFront, Cognito), Docker, GitHub Actions

Frontend : React 19, TypeScript, React Native, Next.js, MUI, Tailwind CSS

FORMATION

Ingénierie Informatique, Data Science — ESPRIT

Tunis · 2021 – 2024

- Mémoire : « IA générative avec connaissances métier » — Mention : Très Bien

Licence en Informatique — ESSECT

Tunis · 2018 – 2021

- Fondations en développement logiciel, algorithmique et structures de données

INFORMATIONS COMPLÉMENTAIRES

- **Langues** : Arabe (Langue maternelle), Anglais (B2, Professionnel), Français (B2, Professionnel)
- **Compétences interpersonnelles** : Résolution de problèmes, collaboration et communication claire